


KCD 스크래핑 엔지니어 프로젝트 요약 문서

1. 수집 프로세스 개요



- ① 사업자등록증으로 받은 상호명(place_name) 기준으로 message_queue 요청
- ② producer에서 '사업장명'과 '사이트명' 정보 보내고 consumer에서 해당 메시지 수신
 - 최초 연동 시 과거 2년 데이터 수집 요청

- 그 후는 요청 날짜 기준 수집

- ③ consumer에서 '사업장명'과 '사이트명' 기준으로 Scraping engine에 기본 정보 수집 요청
- ④ 네이버/카카오 플레이스 사이트로 '사업장'명의 encoding 값을 보내 기본 정보 수집
- ⑤ 기본 정보에서 수집한 '사업장 id'를 기준으로 리뷰 정보 수집
- ⑥ 수집한 기본 및 리뷰 정보를 consumer에 db 저장 요청
- ⑦ 기본 정보 및 리뷰 정보 각각 db 저장

2. 설계 방안 & 에러/장애 감지 및 대응

1) 확장성 고려한 설계 방안

① Kafka

- kafka를 활용해
- Topic 파티셔닝을 통한 병렬 데이터 처리
- Producer와 Consumer의 여러 컨테이너로 확장 가능
- Consumer의 Group을 사용해 병렬로 데이터 소비 가능

② Docker

- kafka, zookeeper, producer, consumer, db를 각 컨테이너로 분리하여 관리

2) 에러 및 장애 감지/대응 방안

[producer]

- 비정상 메시지 생성 시 에러 메시지 출력
- buffer 메모리 에러 시 "producer queue full" 메시지 출력
- 토픽 생성 여부 체크하여 없을 경우 신규 생성

[consumer]

- 사이트 별로 스크래핑 실행하여 장애 대응
- 로깅 테이블에 각 작업 상태 저장하여 이슈가 발생한 작업만 별도 확인 가능
- 정상적으로 메시지를 수신 받지 못했을 경우 에러 메시지 출력 및 재시도
- 정상 메시지 받았을 경우 time.sleep()으로 안정성 확보


[scraper]

- 리뷰 데이터의 경우 많은 양을 수집해야 하므로 에러 발생 시 원인 메시지 출력하여 감지

[db]

- 중복값이 추가되지 않도록 각 테이블 별 고유 id값 기준 설정
- QueuePool 설정하여 연결 재사용으로 오버헤드 감소 및 동시 연결 수 제어를 통해 확장성을 향상시켜 데이터베이스 관리 가능

3. DB 설계 의도



1. 네이버플레이스와 카카오플레이스의 사업장 ID가 상이하기 때문에 사업자등록증 기준으로 수집 가능한 사업장명 기준으로 조회 후 각 플레이스 별 ID 수집
2. 수집한 ID 기준으로 리뷰 정보 수집
3. 각 메시지 처리 상태는 로깅 테이블에 저장
4. 모든 테이블의 id는 PK로 지정

[kcb_info]

- 사업자등록증 기준으로 사업장명 수집 가능
- 사업장명 기준으로 네이버 플레이스 ID, 카카오 플레이스 ID를 수집
- 네이버 ID, 카카오 ID: FK

[naver_info]

- kcb_info의 사업장명(name) 기준으로 네이버 플레이스 기본 정보 수집
- 사업장명 encoding하여 쿼리로 정보 수집
- 네이버 플레이스 ID: FK

[kakao_info]

- kcb_info의 사업장명(name) 기준으로 카카오 플레이스 기본 정보 수집
- 카카오 플레이스의 경우 사업장 id를 수집하기 위해 카카오맵 api 활용(키워드로 장소 검색하기)
- 카카오 플레이스 ID: FK

[naver_review]

- kcb_info의 사업장명(name) 기준으로 네이버 플레이스 리뷰 정보 수집
- 네이버 플레이스 ID: FK

[kakao_review]

- kcb_info의 사업장명(name) 기준으로 카카오 플레이스 리뷰 정보 수집
- 카카오 플레이스 ID: FK

[scraping_jobs]

- 메시지 처리 상태 수집 테이블
- 모든 테이블의 task_id : FK